

# 深層学習による少数学習データでの2次元データの高品質化手法の提案

石原 正敏<sup>†,a</sup>      荒木 徹也<sup>†,b</sup>      石川 博<sup>†,c</sup>

<sup>†</sup> 東京都立大学大学院システムデザイン学部情報科学域

a) [ishihara-masatoshi@ed.tmu.ac.jp](mailto:ishihara-masatoshi@ed.tmu.ac.jp) b) [tetsuya.arakigunma-u.ac.jp](mailto:tetsuya.arakigunma-u.ac.jp) c) [ishikawa-hiroshi@tmu.ac.jp](mailto:ishikawa-hiroshi@tmu.ac.jp)

**概要** 本研究では超解像とガウスノイズ除去の二つの観点からデータ高品質化を行う。近年、火星地表画像の超解像やヒートマップの高品質化など、様々なデータの高品質化が求められる。提案手法の汎用性の評価の為、DIV2K画像データセットを利用する。画像データセットから、 $128 \times 128$  のカラーの部分画像をランダムに切り出したものを学習に使用する。過剰適合を防ぎつつ精度を向上させる為、入出力に直通の迂回路を設置することで過剰適応と精度の両立を行う。解像度の向上とノイズ除去では適切な手法が異なる為、其々の手法を組み合わせることで両立する。この様な工夫により、様々なケースに柔軟に対応した2次元データ高品質化が可能となる。

**キーワード** 深層学習, 超解像処理, ノイズ除去

## 1 はじめに

近年において観測したデータを有効活用するための課題として、二次元データの高品質化がある。取り扱うデータや観測方法によって、特定のノイズが乗りやすさやデータの解像度が不十分であるなど、適切な高品質化の方法は異なる。このように様々なケースに柔軟に対応するために、機械学習によって高品質化を行う事が望ましい。

例えば、高品質化のアプローチ一つに、単一画像超解像 (Single image super resolution) と呼ばれる解像度の低いデータを高解像化する手法がある。月面 DEM の高解像度化 [1] や深海海底地形図の作成 [2], CT や MRI 画像の超解像 [3] が例として挙げられる。高品質化のための他のアプローチとして、ノイズ除去がある。ラマン散乱顕微鏡画像のノイズ除去 [4] や手書き文字画像のノイズ除去 [5] が例として挙げられる。複数の高品質化の為のアプローチに対応した機械学習手法を適応することで、様々なケースに対応できる。

一方で常に十分な学習データが得られるとは限らない。例えば、月面や海底の高度座標など、限られた情報から高品質化の為の学習を行わなければならない場合がある。他にも画像の高品質化の場合は火星の地表や人体の患部など、どの学習データを利用したかが重要視される場合はビッグデータの転移学習などが好ましくない場合も存在する。学習データが不十分な場合、過学習 (Overfitting) と呼ばれる訓練データに対して過剰に適合することで未知のデータに対応不能になる現象が発生する。一般に過学習対策手法は出力データの品質を劣化させるために、品質劣化を抑える必要がある。

本稿では、画像の超解像とガウスノイズ除去を行うこ

とで、二次元データの高品質化を行う少数データでも過学習を起しにくい機械学習手法を提案する。

## 2 関連研究

機械学習のアプローチの一つに、罰則と報酬によって神経接続 (Neural Net) を効率化させていくものがある。この方法は、汎用的な機械学習を実現する手段として注目されてきた [6]。畳み込みニューラルネットワーク (Convolutional Neural Network; CNN)(以降 CNN) と呼ばれる構造の登場は、画像処理に大きな影響を及ぼした [7]。

Nitish S., et al.[8] はランダムで神経細胞 (units) を不活化することで過学習抑制に高い効果を示す Dropout と呼称される手法を提案した。Dong, C., et al.[9] は Super-Resolution Convolutional Neural Network (SRCNN) と呼ばれる三層の CNN から構成される機械学習モデルを提案して、高度な単一画像超解像を行った。SRCNN は低解像度画像を Bicubic 法で拡大したあとに SRCNN を通すことで、超解像を行った。別の研究では、SRCNN はノイズ除去にも利用可能である事が示唆された。Ronneberger, O., et al.[10] は U-Net と呼ばれる U 字型の構造を持つ機械学習モデルにより、画像のセグメンテーションを行った。U-Net の U 字型の構造は、全体的特徴と局所的特徴の両方を処理するという特性があり、単一画像超解像にも応用された。

## 3 提案手法

本稿では、劣化処理を施した劣化部分画像  $x$  から復元部分画像  $\hat{y}$  を生成することで、データの高品質化を行う (図 1)。そこで、部分画像を復元するために用いるための機械学習モデルを提案する。

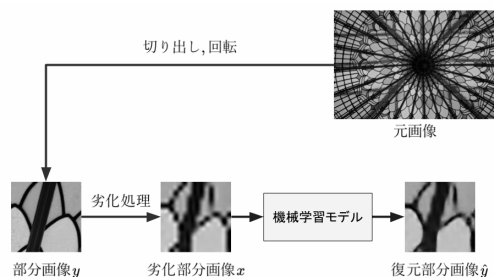


図1 手順概説

### 3.1 高品質化の手順

元画像のデータセットからランダムに画像を選出して  $128 \times 128 \times 3$  のカラー部分画像をランダムに切り出し, 0度, 90度, 180度, 270度のランダムで回転を加えたものを部分画像  $y$  とした. 部分画像  $y$  にノイズの追加, 解像度の変更などの任意の劣化処理を行ったものを劣化部分画像  $x$  とした. 劣化部分画像  $x$  から機械学習で部分画像  $y$  を推測して生成した画像を復元部分画像  $\hat{y}$  とした. 劣化部分画像  $x$  と部分画像  $y$  の比較評価は PSNR と SSIM にて行った.

### 3.2 提案する機械学習モデル

本稿では少数字学習での過学習を防ぎつつ, 複数の高品質化のアプローチを実現する機械学習モデルを提案する. 本稿の機械学習モデルは, U-Net の構造, ガウスノイズ除去用の SRCNN の構造, 迂回路によって構成される (図2). Loss 関数は最小二乗法 (MSE)  $\frac{1}{2} \|y - \hat{y}\|^2$  を使用した.

#### 3.2.1 U-Net

U-Net は全体的特徴と局所の特徴の両方を結合する構造を持つ (図3). U-Net の構造を超解像に利用するに際し, 性能に差異が認められなかったため, 計算コスト削減のために結合部分を加算に変更した. また, U-Net の構造はガウスノイズ除去性能において




図2 提案モデルのネットワーク構造

表1 精度と時間

subject	accuracy [mm]	time [ms]
s1	32	5568
s2	63	382
s3	12	421
s4	51	763

## 4 実験

## 5 結果

## 6 おわりに

### 6.1 図表

「表1」の形式で参照します.

### 参考文献

- [1] 小野寺康祐, 井上 博夏, 山本 光生ほか: 機械学習による月面 DEM の高解像化, 宇宙航空研究開発機構研究開発報告, Vol.9, No.1, pp. 22-32, 2020.
- [2] 伊藤喜代志: 機械学習による超解像技術を活用した詳細な深海海底地形図の作成, 日本水産工学会誌, Vol.56, No.1, p47-50, 2019

- [3] Wei, S., Wu, W., Jeon, G., et al.: Improving resolution of medical images with deep dense convolutional neural network, *Concurrency and Computation: Practice and Experience*, Vol.32, No.1, e5084., 2020.
- [4] Manifold, B., Thomas, E., Francis, A. T., et al.: Denoising of stimulated Raman scattering microscopy images via deep learning., *Biomedical optics express*, vol.10, No.8, 3860-3874, 2019.
- [5] 小松里奈: U-Net による手書き文字画像内のノイズ除去, 人工知能学会全国大会論文集, Vol.32, No.1, p.4M101-4M101, 2018.
- [6] Samuel, A. L.: Some studies in machine learning using the game of checkers, *IBM Journal of research and development*, Vol.3, No.3, pp. 210-229, 1959.
- [7] Lecun, Y., Bottou, L., Bengio, Y., et al.: Gradient-based learning applied to document recognition, *Proceedings of the IEEE*, Vol.86, No.11, pp. 2278-2324, 1998.
- [8] Srivastava, N., Hinton, G., Krizhevsky, A., et al.:




図3 U-Net のネットワーク構造 [Ronneberger, O., et al. 2015]

Dropout: a simple way to prevent neural networks from overfitting, The journal of machine learning research, Vol.15, No.1, pp. 1929-1958, 2014.

- [9] Dong, C., Loy, C. C., He, K., Tang, X., et al.: Learning a Deep Convolutional Network for Image Super-Resolution, in Proceedings of European Conference on Computer Vision (ECCV), pp. 184-199, 2014.
- [10] Ronneberger, O., Fischer, P., Brox, T.: U-net: Convolutional networks for biomedical image segmentation, International Conference on Medical image computing and computer-assisted intervention (MICCAI), pp. 234-241, 2015.