

深層学習による少数学習データでの2次元データの高品質化手法の提案

石原 正敏^{†,a} 荒木 徹也^{†,b} 石川 博^{†,c}

[†] 東京都立大学大学院システムデザイン学部情報科学域

a) ishihara-masatoshi@ed.tmu.ac.jp b) tetsuya.arakigunma-u.ac.jp c) ishikawa-hiroshi@tmu.ac.jp

概要 本稿では超解像とガウシアンノイズ除去の二つの観点からデータ高品質化を行う。近年、火星地表画像の超解像やヒートマップの高品質化など、様々なデータの高品質化が求められる。提案手法の汎用性の評価の為、DIV2K画像データセットを利用する。画像データセットから、 $128 \times 128 \times 3$ のカラーの部分画像をランダムに切り出したものを学習に使用する。過剰適合を防ぎつつ精度を向上させる為、入出力に直通の迂回路を設置することで過剰適応と精度の両立を行う。解像度の向上とノイズ除去では適切な手法が異なる為、其々の手法を組み合わせることによって両立する。この様な工夫により、様々なケースに柔軟に対応した2次元データ高品質化が可能となる。

キーワード 深層学習, 超解像処理, ノイズ除去

1 はじめに

近年において観測したデータを有効活用するための課題として、二次元データの高品質化がある。取り扱うデータや観測方法によって、特定のノイズが乗りやすさやデータの解像度が不十分であるなど、適切な高品質化の方法は異なる。このように様々なケースに柔軟に対応するために、機械学習によって高品質化を行う事が望ましい。

例えば、高品質化のアプローチ一つに、単一画像超解像 (Single image super resolution) と呼ばれる解像度の低いデータを高解像化する手法がある。月面 DEM の高解像度化 [1] や深海海底地形図の作成 [2], CT や MRI 画像の超解像 [3] が例として挙げられる。高品質化のための他のアプローチとして、ノイズ除去がある。ラマン散乱顕微鏡画像のノイズ除去 [4] や手書き文字画像のノイズ除去 [5] が例として挙げられる。複数の高品質化の為のアプローチに対応した機械学習手法を適用することで、様々なケースに対応できる。

一方で常に十分な学習データが得られるとは限らない。例えば、月面や海底の高度座標など、限られた情報から高品質化の為の学習を行わなければならない場合がある。他にも画像の高品質化の場合は火星の地表や人体の患部など、どの学習データを利用したかが重要視される場合はビッグデータの転移学習などが好ましくない場合も存在する。学習データが不十分な場合、過学習 (Overfitting) と呼ばれる訓練データに対して過剰に適合することで未知のデータに対応不能になる現象が発生する。一般に過学習対策手法は出力データの品質を劣化させるために、品質劣化を抑える必要がある。

本稿では、画像の超解像とガウシアンノイズ除去を行

うことで、二次元データの高品質化を行う少数データでも過学習を起しにくい機械学習手法を提案する。

2 関連研究

機械学習のアプローチの一つに、罰則と報酬によって神経接続 (Neural Net) を効率化させていくものがある。この方法は、汎用的な機械学習を実現する手段として注目されてきた [6]。畳み込みニューラルネットワーク (Convolutional Neural Network; CNN)(以降 CNN) と呼ばれる構造の登場は、画像処理に大きな影響を及ぼした [7]。

Nitish S., et al.[8] はランダムで神経細胞 (units) を不活化することで過学習抑制に高い効果を示す Dropout と呼称される手法を提案した。Dong, C., et al.[9] は Super-Resolution Convolutional Neural Network (SRCNN) と呼ばれる3層か4層のCNNから構成される機械学習モデルを提案して、高度な単一画像超解像を行った。当手法は低解像度画像をBicubic法で拡大したあとに当モデルを通すことで、超解像を行った。Ronneberger, O., et al.[11] は U-Net と呼ばれるU字型の構造を持つ機械学習モデルにより、画像のセグメンテーションを行った。U-NetのU字型の構造は、全体的特徴と局所的特徴の両方を処理するという特性があり、単一画像超解像にも応用された。

3 提案手法

本稿では、劣化処理を施した劣化部分画像 x から復元部分画像 \hat{y} を生成することで、データの高品質化を行う (図1)。そこで、部分画像を復元するために用いるための機械学習モデルを提案する。

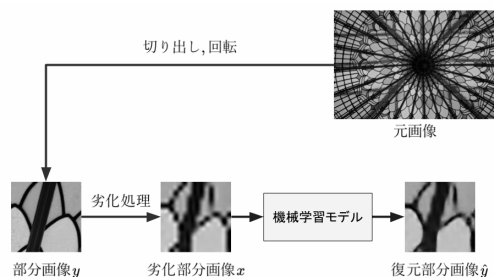


図1 手順概説

3.1 高品質化の手順

元画像のデータセットからランダムに画像を選出して $128 \times 128 \times 3$, 画素値 255 のカラー部分画像をランダムに切り出し, 0 度, 90 度, 180 度, 270 度のランダムで回転を加えたものを部分画像 y とした. 部分画像 y にノイズの追加, 解像度の変更などの任意の劣化処理を行ったものを劣化部分画像 x とした. 劣化部分画像 x から機械学習で部分画像 y を推測して生成した画像を復元部分画像 \hat{y} とした. 劣化部分画像 x と部分画像 y の比較評価には PSNR と SSIM を使用した. 学習に使用する部分画像の枚数 (サンプル数 n) を変更することで, 少数学習が提案する機械学習モデルに及ぼす影響を調査した.

3.1.1 超解像

八倍の単一画像超解像を行った. 部分画像 y の解像度を $16 \times 16 \times 3$ まで縮小したのち Bicubic 法で $128 \times 128 \times 3$ に拡大したものを劣化部分画像 x とした.

3.1.2 ガウシアンノイズ除去

部分画像 y の各画素, 各色に対して平均 $\mu = 0$, 標準偏差 $\sigma = 64$ (画素値の $1/4$) のガウシアンノイズを加えたものを劣化部分画像 x とした.

3.2 提案する機械学習モデル

本稿では少数学習での過学習を防ぎつつ, 複数の高品質化のアプローチを実現する機械学習モデルを提案する (図 2). 図において, 左の U-Net 構造, 中央の SRCNN 構造, 右の迂回路によって構成した. Loss 関数は平均二乗法 (MSE) を使用した. 最終層以外の各層の活性化関数は ReLU を使用し, 最終層は活性化関数無しとした.

3.2.1 U-Net

U-Net は全体的特徴と局所の特徴の両方を結合する構造を持つ (図 3). U-Net の構造を超解像に利用するに際し, 性能に差異が認められなかったため, 計算コスト削減のために結合部分を加算に変更した.

3.2.2 SRCNN

提案する SRCNN 構造は 3 層の CNN によって構成した. U-Net と比較した際, 超解像で劣りガウシアンノイズ除去に優れていたため本モデルに使用した.




図2 提案モデルのネットワーク構造

3.2.3 迂回路

Dropout による過学習対策は, 精度とトレードオフの関係にある. そこで Kaiming, H. et al.[10] の提案した ResNet を参考にして劣化部分画像 x と復元部分画像 \hat{y} に直通の迂回路を設けた. 迂回路を設けることで, 機械学習モデルの積層や Dropout による元画像の情報の劣化を防ぐことが出来た.




図3 U-Net のネットワーク構造 [Ronneberger, O., et al. 2015]

4 実験方法

4.1 使用データ

学習と評価には高品質画像データセットである DIV2K を使用した [12]. DIV2K は学習用 800 枚, 評価用 100 枚の様々なジャンルの画像によって構成されており, 主に単一画像超解像の評価に利用されている. 機械学習に使用するための部分画像のサンプルを学習用 10000 枚, 評価用 1000 枚生成した.

4.2 学習パラメータ

最適化には Adam をパラメータを $\beta_1 = 0.1$, $\beta_2 = 0.999$, 学習率 0.0005 で使用した [13]. 過学習を抑止するための Dropout 率は 0.2 とした. トレーニングの学習方式は, オンライン学習 (batch size=1) で行った. 学習に使用する部分画像のサンプル数 n は [10000, 1000, 100] の 3 パターンで行った. 学習の backpropagations 数は 100000 とした.

4.3 環境

学習データセット作成などの画像処理に OpenCV を使用した. 深層学習フレームワークは Tensorflow, GPU は NVIDIA RTX2080 を使用した. PSNR と SSIM による評価の為に Scikit-image を使用した.

5 実験結果

5.1 ガウシアンノイズ除去による SRCNN の構造の評価

ガウシアンノイズ除去性能を向上させる目的で設けた SRCNN 構造の有効性を実験した結果を示す (図 4). 提案する機械学習モデルにおいて, PSNR, SSIM 両観点から, SRCNN 構造がガウシアンノイズ除去に有効であることが判明した.

5.2 超解像による迂回路の評価

Dropout による情報劣化を低減する目的で設けた迂回路の有効性を実験した結果を示す (図 5). PSNR, SSIM 両観点から迂回路が存在しないと, 元の画像より劣化することが判明した. また, 迂回路が存在しない場合は色彩が暗くなる傾向があった.

超解像の性能は, ガウシアンノイズと比較して学習に使用するサンプル数 n に大きく依存することが判明した. 具体的には, サンプル数 n が 100 未満になると過学習による情報劣化のリスクが上昇すると考えられる.

6 考察

本稿では, 様々なケースに対応した 2 次元データ高品質化のために, 複数の機械学習モデルを組み合わせる手法を提案した. 提案した機械学習により, 深層学習のネットワーク構造において, 複数の目的のネットワークを並

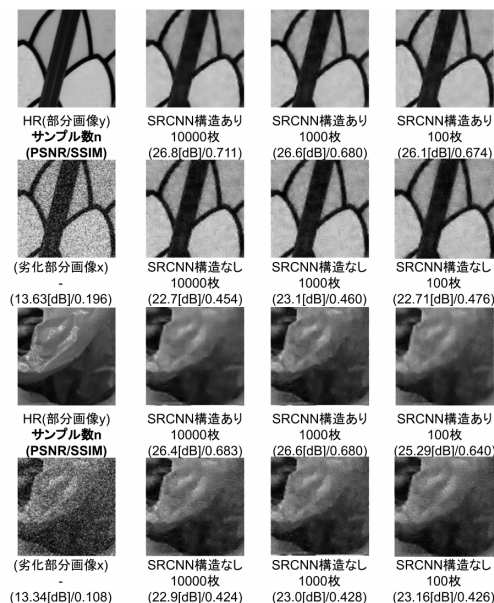


図 4 SRCNN 構造の評価

列に組み合わせることにより, 有効性を示せるタスクの幅を拡張可能であることを示した. 今後の検討課題として, 二次元データ高品質化のために, ボケや歪みなどのより幅広いタスクに対応する必要があると考えられる. また, 画像以外の二次元データの品質化にも対応する必要があると考えられる. そのため, 今後は対応するタスクや状況の設定と, 機械学習モデルの機能拡張を検討する.

参考文献

- [1] 小野寺康祐, 井上 博夏, 山本 光生ほか: 機械学習による月面 DEM の高解像化, 宇宙航空研究開発機構研究開発報告, Vol.9, No.1, pp. 22-32, 2020.
- [2] 伊藤喜代志: 機械学習による超解像技術を活用した詳細な深海海底地形図の作成, 日本水産工学会誌, Vol.56, No.1, p47-50, 2019
- [3] Wei, S., Wu, W., Jeon, G., et al.: Improving resolution of medical images with deep dense convolutional neural network, Concurrency and Computation: Practice and Experience, Vol.32, No.1, e5084., 2020.
- [4] Manifold, B., Thomas, E., Francis, A. T., et al.: Denoising of stimulated Raman scattering microscopy images via deep learning, Biomedical optics express, vol.10, No.8, 3860-3874, 2019.
- [5] 小松里奈: U-Net による手書き文字画像内のノイズ除去, 人工知能学会全国大会論文集, Vol.32, No.1, p.4M101-4M101, 2018.
- [6] Samuel, A. L. : Some studies in machine learning using the game of checkers, IBM Journal of research and development, Vol.3, No.3, pp. 210-229, 1959.
- [7] Lecun, Y., Bottou, L., Bengio, Y., et al.: Gradient-based learning applied to document recognition, Proceedings of the IEEE, Vol.86, No.11, pp. 2278-2324, 1998.
- [8] Srivastava, N., Hinton, G., Krizhevsky, A., et al.:

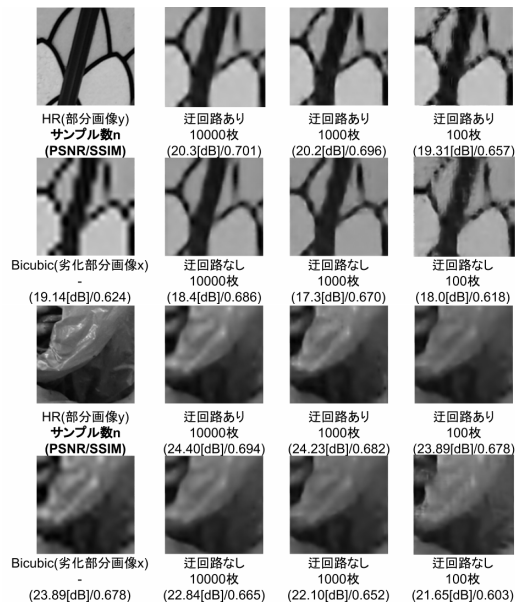


図 5 迂回路の評価

Dropout: a simple way to prevent neural networks from overfitting, The journal of machine learning research, Vol.15, No.1, pp. 1929-1958, 2014.

- [9] Dong, C., Loy, C. C., He, K., Tang, X., et al.: Learning a Deep Convolutional Network for Image Super-Resolution, in Proceedings of European Conference on Computer Vision (ECCV), pp. 184-199, 2014.
- [10] He, K., Zhang, X., Ren, S., et al.: Deep Residual Learning for Image Recognition, 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016
- [11] Ronneberger, O., Fischer, P., Brox, T.: U-net: Convolutional networks for biomedical image segmentation, International Conference on Medical image computing and computer-assisted intervention (MICCAI), pp. 234-241, 2015.
- [12] Timofte, R., Agustsson, E., Gool, L. V., et al.: NTIRE 2017 challenge on single image super-resolution: Methods and results, IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW), 2017.
- [13] Kingma, D. P., Ba, J. L., et al.: Adam: A Method for Stochastic Optimization, International Conference on Learning Representations (ICLR), 2015.